

Optimizavimo metodai

Netiesinis programavimas

Apribojimai

- ▶ Kiekvienas inžinierius žino, kiek daug visokių sąlygų bei apribojimų būtina įvertinti projektuojant.
- ▶ Techniniuose reikalavimuose paprastai būna nurodyta daug ribinių projektuojamojo objekto charakteristikų reikšmių, reikalavimai konstrukcinėms medžiagoms ir pan.
- ▶ Pavyzdžiui, masė ir kaina turi būti mažesnės, o patikimumas didesnis už tam tikras nustatytas reikšmes.
- ▶ Taip pat būtina atsižvelgti į projektuojamojo objekto charakteristikas siejančius gamtos dėsnius.
- ▶ Todėl techniniai optimizavimo uždaviniai dažniausiai būna su apribojimais.
- ▶ Panašiai formuluojami ir ekonominio planavimo uždaviniai, nes tenka atsižvelgti ir į turimas atsargas, ir į biudžeto ribotumą, ir į reikalavimus terminams, ir t.t.

Apribojimai optimizavimo uždavinyje

- ▶ Formuluoiant uždavinį matematiškai, apribojimais vadinamos leistinąją sritį apibrėžiančios lygybės ir nelygybės, pavyzdžiui,

$$\begin{aligned}\min f(X), X &= (x_1, \dots, x_n), \\ g_i(X) &\leq 0, i = 1, \dots, k, \\ g_i(X) &= 0, i = k + 1, \dots, m,\end{aligned}$$

reiškia funkcijos $f(X)$ minimizavimą leistinoje srityje, apibrėžtoje funkcijų $g_i(X)$ neteigiamumo arba lygybės nuliui reikalavimais.

- ▶ Patenkinantis apribojimus taškas X vadinamas (optimizavimo uždavinio) leistinu sprendiniu.
- ▶ Minimumo taškas vadinamas optimaliu sprendiniu, arba trumpiau, sprendiniu.
- ▶ Pirmieji k apribojimų vadinami nelygybiniais, kiti – lygybiniais.


Optimizavimo uždavinių klasifikacija

- ▶ Apribojimai klasifikuojami į tiesinius ir netiesinius, žiūrint kokios funkcijos $g_i(X)$.
- ▶ Jei bent viena iš tikslo arba apribojimų funkcijų yra netiesinė, toks optimizavimo uždavinys vadinamas netiesinio programavimo uždaviniu, jei jos visos iškilosios – iškilosio programavimo uždaviniu.
- ▶ Uždavinių su apribojimais lokaliajo optimizavimo metodai sudaromi iš metodų be apribojimų, juos modifikuojant taip, kad būtų įvertinama ne tik funkcijos mažėjimo kryptis, bet ir apribojimai.

Minimumo sąlygos

- ▶ Anksčiau nagrinėta būtina minimumo sąlyga uždaviniams be apribojimų, išreikšta funkcijos gradiento lygybe nuliui.
- ▶ Esant apribojimams, funkcijos gradientas gali būti nelygus nuliui visoje leistinoje srityje.
- ▶ Tada minimumas pasiekiamas taške X^* , esančiame ant leistinosios srities krašto.
- ▶ Būtiną minimumo sąlygą galima paaiškinti geometriškai: jei taške X^* pasiekiamas lokalusis minimumas, tai leistinoje srityje jokia kryptimi negalima sumažinti tikslo funkcijos reikšmės.
- ▶ Todėl tikslo funkcijos gradientas taške X^* turi būti ortogonalus leistinosios srities liečiamajai hiperplokštumai.
- ▶ Nelygybiniai apribojimai, kurie taške X patenkinami kaip lygybės, vadinami aktyviais; jų indeksų aibę pažymėsime $I^*(X)$, ir $I(X) = I^*(X) \cup \{k + 1, \dots, m\}$.

Būtinų minimumo sąlygų iliustracija



Minimumo sąlygos optimizavime su apribojimais

- ▶ Jei X^* yra lokalinio minimumo taškas, tai egzistuoja tokie visi kartu nelygūs nuliui daugikliai $\lambda_i, i = 0, \dots, m$, kad $\lambda_i \geq 0, i = 1, \dots, k$,

$$\lambda_0 \nabla f(X^*) + \sum_{i=1}^m \lambda_i \nabla g_i(X^*) = 0,$$

$$\lambda_i g_i(X^*) = 0, i = 1, \dots, k.$$

- ▶ Svarbus šios teoremos atvejis $\lambda_0 \neq 0$ įrodomas esant papildomai regularumo prielaidai, pavyzdžiui, $\nabla g_i(X^*), i \in I(X^*)$ yra tiesiškai nepriklausomi.
- ▶ Tada teoremos formulavime galima rašyti $\lambda_0 = 1$, o gautos būtinos minimumo sąlygos vadinamos Karush-Kuhn-Tucker (KKT) sąlygomis

$$\nabla f(X^*) + \sum_{i=1}^m \lambda_i \nabla g_i(X^*) = 0,$$

$$\lambda_i \geq 0, \lambda_i g_i(X^*) = 0, i = 1, \dots, k.$$

Nepatenkintų reguliarumo sąlygų pavyzdys

Reguliarumo sąlygos netenkinamos uždavinio


$$\min(x_1 - 10)^2 + x_2^2,$$

$$x_2 \leq 7 - \sqrt{-x_1^2 + 14x_1},$$

$$0 \leq x_1 \leq 8,$$

$$0 \leq x_2 \leq 8,$$

minimumo taške $(0, 7)$, nes abiejų aktyvių apribojimų gradientai yra statmeni abscisių ašiai, kuria yra nukreiptas tikslo funkcijos gradientas.



Lagrange'o funkcija

- ▶ Daugelis netiesinio programavimo metodų susiję su Lagrange'o funkcija

$$L(X, \Lambda) = f(X) + \sum \lambda_i \cdot g_i(X).$$

- ▶ Jei Lagrange'o funkcija diferencijuojama, tai minimumo sąlygas (priėmus reguliarumo prielaidą) galima užrašyti naudojantis Lagrange'o funkcija

$$\begin{aligned}\nabla_X L(X, \Lambda) &= 0, \\ \lambda_i &\geq 0, \quad i \in I^*(X^*), \\ \lambda_i g_i(X^*) &= 0, \quad i = 1, \dots, k.\end{aligned}$$

- ▶ Lagrange'o funkcijos terminais galima suformuluoti būtinas minimumo sąlygas, kurios nereikalauja, kad funkcijos $f(X)$, $g_i(X)$, $i = 1, \dots, m$, būtų diferencijuojamos.

Būtinios minimumo sąlygos

- ▶ Tarkime, optimizavimo uždavinys turi tik nelygybinius apribojimus, visos šio uždavinio funkcijos iškilosios ir apribojimai tenkina reguliarumo sąlygą: egzistuoja toks taškas X , kuriame nelygybės tenkinamos griežtai:
 $g_i(X) > 0, i = 1, \dots, k$.
- ▶ Tada lokaliojo minimumo taškas X^* lemia Lagrange'o funkcijos balno tašką, t.y. egzistuoja tokie $\lambda_{0i} \geq 0, i = 1, \dots, k$, kad

$$L(X^*, \Lambda) \leq L(X^*, \Lambda_0) \leq L(X, \Lambda_0)$$

su visais $\lambda_i \geq 0, X \in \mathbb{R}^n$.

- ▶ Tas rodo, kad lokaliojo minimumo su sudėtingais apribojimais ieškojimas gali būti pakeistas Lagrange'o funkcijos balno taško ieškojimu esant paprastiems apribojimams $\lambda_i \geq 0$.
- ▶ Šios būtinios minimumo sąlygos vadinamos (Kuhn-Tucker) teorema apie balno tašką.

Minimumo sąlygos

- ▶ Uždavinių su apribojimais būtinos minimumo sąlygos tiriamos jau seniai.
- ▶ Vienas iš svarbiausių dar ir šiandien yra Lagrange'o pasiūlytas principas – perkelti apribojimus į tikslo funkciją.
- ▶ Kuhn-Tucker sąlygos išvestos remiantis ta pačia idėja.
- ▶ Atrodytų, pakankamos minimumo sąlygos svarbesnės už būtinas. Tačiau jos gerokai sudėtingesnės.
- ▶ Be to, jas galima suformuluoti tik tuo atveju, kai visos optimizavimo uždavinio funkcijos tenkina griežtus reikalavimus, kurių praktiniuose uždaviniuose dažniausiai neįmanoma patikrinti.
- ▶ Todėl stengiamasi suformuluoti praktiškai patikrinamas būtinas sąlygas, kaip galima artimesnes pakankamoms.
- ▶ Vienas iš svarbiausių teorinių netiesinio programavimo metodų pagrindimų yra įrodymas, kad pagal tuos metodus generuojamų taškų seka artėja prie taško, tenkinančio būtinas minimumo sąlygas.

Dualumas: pirminis uždavinys

- Nagrinėsime minimizavimo uždavinį, kurį vadinsime pirminiu

$$\begin{aligned}\mathbf{P} : \min f(X), \\ g_i(X) \leq 0, \quad i = 1, \dots, k, \\ h_i(X) = 0, \quad i = 1, \dots, m,\end{aligned}$$

čia lygybinių ir nelygybinių apribojimų funkcijas pažymėjome skirtingomis raidėmis, kadangi apie skirtingų tipų apribojimus bus daromos skirtingos prielaidos.

- Be to, darysim prielaidą, kad $\mathbf{P}$ uždavinio kintamųjų vektorius priklauso paprastos struktūros aibei $X \in A_0$, kuri nėra aprašoma apribojimų funkcijomis. Pavyzdžiui, $A_0 = \{X : x_i \geq 0, i = 1, \dots, n\}$; dažnai A_0 tiesiog sutampa su $\mathbb{R}^n$. Leistina aibė, kaip paprastai, žymima A .
- Pirminio $\mathbf{P}$ uždavinio Lagrange'o funkcija užrašoma šitaip

$$L(X, U, V) = f(X) + \sum_{i=1}^k u_i g_i(X) + \sum_{i=1}^m v_i h_i(X) = f(X) + UG(X) + VH(X).$$

Dualumas: dualus uždavinys

- Dualiu vadinamas maksimizavimo uždavinys

$$\mathbf{D} : \max \Theta(U, V),$$

$$U \geq 0, V \in \mathbb{R}^m,$$

kurio tikslo funkcija apibrėžiama kaip Lagrange'o funkcijos minimalios reikšmės X atžvilgiu priklausomybė nuo U ir V

$$\Theta(U, V) = \inf_{X \in A_0} L(X, U, V);$$


čia parašytas simbolis $\inf$ apibrėžia analogišką minimumui reikšmę, kai pastarasis neegzistuoja, pavyzdžiui, jei galima rasti norimai mažą funkcijos reikšmę, tai minimumas neegzistuoja, o infimumas lygus $-\infty$.

Geometrinė dualaus uždavinio interpretacija

- ▶ Geometrinę prasmę paaiškinsime pavyzdžiu

$$\min f(X), g(X) \leq 0, X \in A_0.$$

- ▶ Pažymėkime $y = g(X)$, $z = f(X)$, ir Γ – vektoriiaus (y, z) reikšmių aibę, kai $X \in A_0$.
- ▶ **P** uždavinio minimumas atitinka aibės Γ tašką ant z ašies su minimalia z reikšme $f(\bar{X})$.



Geometrinė dualaus uždavinio interpretacija

- ▶ **P** uždavinį atitinka **D** uždavinys $\max_{u \geq 0} \Theta(u)$,

$$\Theta(u) = \min_{X \in A_0} f(X) + u \cdot g(X) = \min(z + u \cdot y).$$

- ▶ Esant fiksuotai $u \geq 0$ reikšmei $\Theta(u)$ priklauso nuo dviejų parametrų z ir y , o pastaroji priklausomybė geometriškai reiškia tiesę

$$z = \Theta(u) - u \cdot y,$$

kuri yra žemiausiai z atžvilgiu einanti tiesė, turinti bent vieną bendrą tašką su Γ , t.y. aibės Γ apatinė lietėja su krypties koeficientu $-u$.

- ▶ $\Theta(u)$ reikšmė lygi z reikšmei, gaunamai susikirtus tiesei su z ašimi.
- ▶ Dualus uždavinys: rasti $u \geq 0$ reikšmę $\bar{u}$, maksimizuojančią $\Theta(u)$.
- ▶ Geometriškai $-\bar{u}$ reikštų krypties koeficientą lietėjos, einančios per tašką $y = 0$, $z = f(\bar{X})$, vaizduojantį optimalų **P** uždavinio sprendinį.

Dualumo savybės

- ▶ Sakysim X yra leistinas $\mathbf{P}$ uždavinio sprendinys, o (U, V) – leistinas $\mathbf{D}$ uždavinio sprendinys. Tada galioja nelygybė

$$f(X) \geq \Theta(U, V).$$


- ▶ Savybės:

$$\inf_{X \in A} f(X) \geq \sup_{U \geq 0, V \in \mathbb{R}^m} \Theta(U, V).$$

- ▶ Jei $f(\bar{X}) = \Theta(\bar{U}, \bar{V})$, $\bar{X} \in A$, $\bar{U} \geq 0$, tai $\bar{X}$ ir $(\bar{U}, \bar{V})$ yra $\mathbf{P}$ ir $\mathbf{D}$ uždavinių sprendiniai.
- ▶ Jei, $\inf_{X \in A} f(X) = -\infty$, tai ir $\Theta(U, V) = -\infty$, $\forall U \geq 0$. Jei $\sup_{U \geq 0} \Theta(U, V) = \infty$, tai $\mathbf{P}$ neturi leistinų sprendinių.


Dualumo tarpas

- Bendru atveju galioja nelygybė, t.y. **P** uždavinio minimumas ne mažesnis už **D** maksimumą.
- Kai jie nesutampa, skirtumas vadinamas dualumo tarpu.




Dualumo tarpo pavyzdys

- **P**: $\min f(X) = \min(-2x_1 + x_2)$, $h(X) = x_1 + x_2 - 3 = 0$,
 $A_0 = \{(0,0), (0,4), (4,4), (4,0), (1,2), (2,1)\}$.
- Lygybinį apribojimą patenkina du aibės A_0 taškai, o minimumo taškas yra $\bar{X} = (2,1)$; $f(\bar{X}) = -3$.



Dualumo tarpo pavyzdys

- **D:** $\max \Theta(v), \Theta(v) = \min_{x \in A_0} (-2x_1 + x_2 + v \cdot (x_1 + x_2 - 3)).$



- Tada:

$$\Theta(v) = \begin{cases} -4 + 5v, & v \leq -1, \\ -8 + v, & -1 < v \leq 2, \\ -3v, & v > 2, \end{cases}$$

todėl $\max \Theta(v) = \Theta(2) = -6$.

- Šiuo atveju dualumo tarpas lygus 3.

Baudos ir barjerų metodai

- ▶ Paprastumo dėlei tarkime, kad tikslo funkcija apibrėžta su visais $X \in \mathbb{R}^n$, ir žinomas leistinosios srities vidaus taškas X_1 .
- ▶ Pradiniu tašku parinkus X_1 , lokalųjį minimumą, jei toks egzistųotų srities viduje, galima būtų rasti naudojant metodą, skirtą uždaviniams be apribojimų.
- ▶ Tačiau techniniuose bei ekonominiuose optimizavimo uždaviniuose minimumas dažniausiai pasiekiamas leistinosios srities ribiniame taške.
- ▶ Pagal ieškojimo be apribojimų metodą gauta trajektorija, prasidedanti taške X_1 , šiuo atveju išeina už leistinosios srities, pažeisdama apribojimą $g_i(X) \leq 0$.
- ▶ Trajektorijos dalis iki susikirtimo su apribojimu galėtų būti gauta ir pagal metodą be apribojimų.
- ▶ Trajektorijos tąsa turi kompromisiškai suderinti funkcijos mažėjimo kryptį ir apribojimus.

Baudos funkcija

- ▶ Bendrą funkcijos reikšmės sumažėjimą ir apribojimų pažeidimą įvertina vadinamoji baudos funkcija

$$B(X, r) = f(X) + \frac{1}{r}b(X),$$

čia $b(X) = 0$, jei apribojimai nepažeisti:

$g_i(X) \leq 0, i = 1, \dots, k, g_i(X) = 0, i = k + 1, \dots, m$, ir
 $b(X) > 0$, jei apribojimai pažeisti; $r > 0$.

- ▶ Antrasis baudos funkcijos dėmuo rodo, kad apribojimų pažeidimas ekvivalentus tam tikram tikslo funkcijos reikšmės padidėjimui.
- ▶ Dažnai naudojamos kvadratinė ir absoliuti baudos:

$$b(X) = \sum_{i=1}^k (\max(0, g_i(X)))^2 + \sum_{i=k+1}^m (g_i(X))^2,$$

$$b(X) = \sum_{i=1}^k (\max(0, g_i(X))) + \sum_{i=k+1}^m |g_i(X)|.$$

Optimizavimas uždavinių seka

- ▶ Baudos funkcija $B(X, r)$ su pakankamai mažu r staigiai didėja už leistinosios srities ribų.
- ▶ Parametrui r artėjant prie nulio, $B(X, r)$ minimumo taškas artėja prie uždavinio sprendinio.
- ▶ Todėl optimizavimo uždavinys keičiamas seka uždavinių su diferencijuojama funkcija $b(X)$, apibrėžiama mažėjančia parametru r seka.
- ▶ Kiekvieno paskesnio uždavinio pradinis taškas yra ankstesnio uždavinio sprendinys.
- ▶ Paprastai, mažinant r , griežtinamos ir metodo be apribojimų sustojimo sąlygos.

- ▶ Galima parodyti, kad egzistuoja toks pakankamai mažas r_0 , kad, $r \leq r_0$ absoliučios baudos funkcijos minimumas sutaps su sprendiniu.
- ▶ Todėl optimizavimo su apribojimais uždavinį galima pakeisti vienu minimizavimo uždaviniu, bet su nediferencijuojama, pavyzdžiui absoliutinės baudos, funkcija.
- ▶ Diferencijuojamą baudos funkciją, kai parametro r reikšmės mažos, sunku minimizuoti, nes baudos funkcijos hesianas blogai apibrėžtas, t.y. minimumo taškas yra gilaus griovio dugne. Tam tikrų sunkumų kyla ir tuo atveju, kai baudos funkcija nediferencijuojama.

Barjerų metodas

- ▶ Vartojant baudos metodus, generuojama seka taškų, artėjančių prie sprendinio iš leistinosios srities išorės.
- ▶ Kartais tikslo funkcija būna apibrėžta tik leistinoje srityje.
- ▶ Tada optimizavimo metodo generuojami taškai turi likti srities viduje viso minimizavimo proceso metu.
- ▶ Barjerų funkcija skiriasi nuo baudos tuo, kad ji ima staigiai didėti artėjant prie apribojimų ir dar jų nepažeidus.
- ▶ Metodu be apribojimų gauta tokios funkcijos minimizavimo trajektorija ima krypti išilgai uždavinio apribojimų, jų dar nepasiekus.
- ▶ Aišku, barjerų metodas vartotinas tik tuo atveju, kai apribojimai nelygybiniai ir leistinosios srities hipertūris nelygus nuliui.
- ▶ Plačiausiai vartojama logaritminė barjerų funkcija

$$B(X, r) = f(X) - r \sum_{l=1}^k \ln(-g_l(X)).$$

Barjerų ir baudos metodų analogija

- ▶ Vartojant barjerų metodą, uždavinys su apribojimais keičiamas uždavinių be apribojimų seka su $r \rightarrow 0$.
- ▶ Analogija tarp barjerų ir baudos metodų akivaizdi. Dėl šios analogijos abu metodai dažnai vadinami baudos metodais, tik vienas išorinės baudos, o kitas vidinės baudos metodu.
- ▶ Sustojimo sąlyga nustatoma pagal mažą minimumo taško pokytį keliems gretimiesiems uždaviniams be apribojimų, t.y. su keliomis mažėjančiomis parametro r reikšmėmis.

Baudos metodų taikymas

- ▶ Baudos metodas gana plačiai vartojamas techniniams optimizavimo uždaviniams spręsti.
- ▶ Jis efektyvus tada, kai baudos funkcija natūraliai išplaukia iš techninio uždavinio formuluotės.
- ▶ Baudos metodas, kartais to nesuvokiant, vartojamas daugiakriteriam optimizavimo uždaviniui pakeisti vienkriteriu.
- ▶ Uždavinio formulavimo etape inžinieriai išskiria vieną kriterijų kaip tikslo funkciją, kitus kriterijus pakeisdami apribojimais.
- ▶ Po to programuotojai, vartodami baudos metodą, apribojimus perkelia į tikslo funkciją.
- ▶ Taip visi kriterijai pakeičiami vienu.
- ▶ Kadangi toks pakeitimas nevienintelis ir toli gražu ne visada geriausias, reikėtų jį pagrįsti techninio uždavinio analize.

Baudos metodų taikymas

- ▶ Baudos metodas gana plačiai taikomas tiek teoriniuose tyrimuose, tiek konstruojant algoritmus.
- ▶ Beje, jis gan gerai tinka daugiaekstremių uždavinių su apribojimais apytiksliam globaliajam minimumui įvertinti.
- ▶ Lokaliojo minimizavimo uždaviniams spręsti baudos ir barjerų metodai buvo plačiai vartojami septintajame dešimtmetyje.
- ▶ Pagrindinis šių metodų trūkumas – baudos ir barjerų funkcijų reljefe susidaro gilūs sudėtingos formos grioviai, kuriuose nusileidimo metodų žingsniai negali būti ilgi.
- ▶ Šiuo metu lokaliojo minimizavimo uždaviniams su diferencijuojamomis tikslo ir apribojimų funkcijomis spręsti sukurti efektyvūs metodai, kuriuose netiesiogiai panaudojamos baudos funkcijos, kombinuojant jas su Lagrange'o funkcijomis.
- ▶ Pastaruoju metu baudos funkcijų idėja pergyvena savo renesansą ryšium su vidinio taško metodų teorija.

Leistinių kryptių metodai

- ▶ Šios klasės metodų pagrindinė idėja – rasti kryptį, nepažeidžiančią apribojimų, kuria tikslo funkcija mažėtų.
- ▶ Nenulinis vektorius D vadinamas leistina kryptimi taške X , jei egzistuoja toks r_0 , kad $X + rD$ tenkina apribojimus su visais $0 < r < r_0$.
- ▶ Vektorius D vadinamas leistina nusileidimo kryptimi, jei egzistuoja toks r_0 kad $f(X + rD) < f(X)$ ir $X + rD$ tenkina apribojimus su visais $0 < r < r_0$.
- ▶ Pasirinkus leistiną nusileidimo kryptį, žingsnis paprastai nustatomas, minimizuojant tikslo funkciją šia kryptimi, t.y. sprendžiant vienmatį minimizavimo uždavinį.
- ▶ Įvairūs metodai skiriasi krypties ir žingsnio parinkimu.
- ▶ Paprastai šis metodas taikomas tada, kai apribojimai tiesiniai arba netiesiniai nelygybiniai.

Leistinių krypčių metodo pavyzdys

- Dėl paprastumo nagrinėkime uždavinį su tiesiniais apribojimais:

$$\min f(X), AX + B \leq 0, CX + E = 0,$$

čia, A ir C yra $k \times n$ ir $(m - k) \times n$ dimensijų matricos, o B ir E yra k ir $m - k$ dimensijų vektoriai, 0 – nulinis atitinkamo dimensijos vektorius, pavyzdžiui, uždavinio

$$f(X) = (x_1 - 7)^2 + (x_2 - 5)^2,$$

$$A = \begin{pmatrix} -1 & 1 \\ 2 & 1 \\ -1 & 0 \\ 0 & -1 \end{pmatrix}, B = \begin{pmatrix} -3 \\ -15 \\ 0 \\ 0 \end{pmatrix},$$

tikslo funkcija yra kvadratinė, o keturi apribojimai yra tiesiniai nelygybiniai.

Leistinių kryptų metodo pavyzdys

- ▶ Suformuluotą uždavinį spręsimė leistinių kryptų metodų pagrindėjo Zoutendijk'o metodu.
- ▶ Sakykime X_k – taškas leistinoje srityje.
- ▶ Jei visi nelygybiniai apribojimai tenkinami kaip griežtos nelygybės, tai X_k yra vidinis leistinosios srities taškas.
- ▶ Iš jo galima žengti metodo be apribojimų žingsnį iki susikirtimo su leistinosios srities riba.
- ▶ Jei taškas X_k yra srities riboje, tai apribojimai, tenkinami kaip lygybiniai, vadinami aktyviais apribojimais.
- ▶ Leistinajai kryptiai iš taško, esančio ant srities krašto, nustatyti sprendžiamas tiesinio programavimo uždavinys:

$$\min_D \nabla f(X_k)D, \quad A_1 D \leq 0, \quad CD = 0, \quad -1 \leq d_i \leq 1, \quad i = 1, \dots, n,$$

čia A_1 yra matricos A dalis, atitinkanti aktyvius apribojimus.

- ▶ Geometrinė uždavinio prasmė šitokia: ieškoma krypties, tenkinančios aktyvius apribojimus ir sudarančios minimalų kampą su antigradiento kryptimi.

Leistinių krypčių metodo pavyzdys

- ▶ Sakykime, pavyzdyje $X_k = (4, 7)$.
- ▶ Tada pirmieji du apribojimai yra aktyvūs, o tikslo funkcijos gradientas taške X_k lygus $(-6, 4)$.
- ▶ Taigi, leistinajai kryptiai nustatyti reikia spręsti tiesinio programavimo uždavinį:

$$\min(-6d_1 + 4d_2),$$

$$-d_1 + d_2 \leq 0,$$

$$2d_1 + d_2 \leq 0,$$

$$-1 \leq d_1, d_2 \leq 1.$$

- ▶ Pagalbinio tiesinio programavimo uždavinio sprendinys yra $D_k = (1/2, -1)$, o minimali tikslo funkcijos reikšmė lygi -7 .
- ▶ Šiuo atveju tikslo funkcijos minimumas kryptimi D_k sutampa su uždavinio sprendiniu.
- ▶ Jei taip nebūtų, rastame taške būtų galima nustatyti naują leistinąją kryptį ir tęsti iteracinį procesą.

Leistinių krypčių metodo apibendrinimai

- ▶ Šį metodą galima modifikuoti uždaviniams su netiesiniais apribojimais.
- ▶ Aktyvieji apribojimai taške X_k aproksimuojami tiesiniais, t.y. $g_i(X) \approx g_i(X_k) + \nabla g_i(X_k)(X_k - X)$.
- ▶ Kaip ir anksčiau, leistinoji kryptis nustatoma aproksimuotam uždaviniui.
- ▶ Minimizuojant tikslo funkciją šia kryptimi, gaunamas naujas taškas X_{k+1} ir t.t.
- ▶ Šį metodą galima apibendrinti, įvertinant tikslo funkcijos, išskleistos Taylor'o eilute, aukštesnės eilės narius.
- ▶ Tada ieškoma krypties, tenkinančios ištiesintus apribojimus ir mažiausiai besiskiriančios nuo krypties, rodančios į aproksimuotos kvadratinės funkcijos tikslo funkcijos minimumo tašką.
- ▶ Suprantama, aproksimuojančioji kvadratinė funkcija turi būti teigiamai apibrėžta.
- ▶ Jei apribojimai labai netiesiniai, metodai neefektyvūs dėl trumpo žingsnio kiekvienoje iteracijoje.

Gradientų projekcijų ir redukcijų metodai

- ▶ Projekcijų metodai plačiai taikomi uždaviniams su tiesiniais apribojimais spręsti.
- ▶ Jie ypač efektyvūs (palyginti su kitais), kai yra daug kintamųjų.
- ▶ Remiantis išdėstytomis idėjomis, kintamosios metrikos metodai be apribojimų nesunkiai modifikuojami uždaviniams su tiesiniais apribojimais.
- ▶ Tereikia modifikuoti hesiano perskaiciavimo formules taip, kad būtų įvertinami aktyvių apribojimų aibės pasikeitimai, t.y. jos sumažėjimas arba papildymas naujais apribojimais.

Rosen'o metodas

- ▶ Rosen'o metodas – vienas iš plačiausiai naudojamų gradientų projekcijų metodų.
- ▶ Juo realizuojama ortogonalio gradiento projekcija į ištiesintus aktyvius apribojimus.
- ▶ Dėl paprastumo tarkime, kad apribojimai tiesiniai.
- ▶ Iš pradinio taško pagal minimizavimo be apribojimų metodą einama iki trajektorijos sankirtos su leistinosios srities riba.
- ▶ Gali atsitikti ir taip, kad antigradientas kai kurių iš apribojimų, kurie tenkinami kaip lygybės, atžvilgiu nukreiptas į leistinosios srities vidų. Tada tokie apribojimai išbraukiami iš aktyvių apribojimų sąrašo.
- ▶ Antigradientas projektuojamas į aktyvių apribojimų sankirtą. Projekcija apskaičiuojama dauginant antigradientą iš matricos, sudarytos iš aktyvių apribojimų (tiesinių nelygybių) koeficientų. Šia kryptimi ieškoma tikslo funkcijos minimumo.
- ▶ Nauja iteracija pradedama aktyvių apribojimų sąrašo sudarymu ir t.t.

Projekcijos apskaičiavimas Rosen'o metode

- ▶ Iš aktyvių apribojimų gradientų taške X_k sudaroma matrica N :

$$N = (\nabla g_1(X_k), \nabla g_2(X_k), \dots, \nabla g_m(X_k)).$$

- ▶ Apskaičiuojama projekcijos matrica

$$P = I - N(N^T N)^{-1} N^T.$$

- ▶ Paieškos kryptis randama dauginant matricą P iš tikslo funkcijos antigradiento:

$$S_k = -P \nabla f(X_k).$$

Rosen'o metodas su netiesiniais apribojimais

- ▶ Rosen'o metodas, apibendrintas uždaviniams su netiesiniais apribojimais, artimas leistinųjų krypčių metodei ir remiasi tiesine apribojimų aproksimacija.
- ▶ Kadangi einant liestine, galima gerokai nutolti nuo leistinosios srities, tai daromas tik nedidelis žingsnelis ir gautas taškas koreguojamas, projektuojant jį į netiesinius apribojimus.
- ▶ Projekcija apskaičiuojama iteraciniais metodais, kurie artimi optimizavimo be apribojimų metodams.
- ▶ Žengti didelį žingsnį liestinės kryptimi gali būti neracionalu, kad nebūtų per daug nutolta nuo leistinosios srities.

Redukcijos metodai

- ▶ Redukcijos metodų idėja ta, kad dalis kintamųjų traktuojami kaip priklausomi ir gali būti išreikšti nepriklausomais kintamaisiais sprendžiant aktyviųjų apribojimų lygtis.
- ▶ Aktyviųjų tiesinių apribojimų lygtys sprendžiamos gana lengvai, bet eliminuoti priklausomus kintamuosius netiesinių apribojimų atveju, sprendžiant (netiesines) lygtis, praktiškai neįmanoma.
- ▶ Tačiau palyginti paprastai galima gauti priklausomų kintamųjų diferencialines charakteristikas.

Redukcijos metodas: dviejų kintamųjų atvejis

- ▶ Panagrinėkime uždavinį su vienu apribojimu $g(x_1, x_2) = 0$.
- ▶ Tikslų ir apribojimo funkcijų diferencialai lygūs:

$$\partial f(X) = \frac{\partial f(X)}{\partial x_1} dx_1 + \frac{\partial f(X)}{\partial x_2} dx_2, \quad \partial g(X) = \frac{\partial g(X)}{\partial x_1} dx_1 + \frac{\partial g(X)}{\partial x_2} dx_2.$$

- ▶ Kadangi iš $g(x_1, x_2) = 0$ išplaukia, kad $\partial g(X) = 0$,

$$dx_2 = - \left(\frac{\partial g(X)}{\partial x_1} / \frac{\partial g(X)}{\partial x_2} \right) dx_1,$$

$$\partial f(X) = \left(\frac{\partial f(X)}{\partial x_1} - \left(\frac{\partial f(X)}{\partial x_2} \cdot \frac{\partial g(X)}{\partial x_1} / \frac{\partial g(X)}{\partial x_2} \right) \right) dx_1.$$

Redukuota $f(X)$ išvestinė x_1 atžvilgiu

$$\frac{df(X)}{dx_1} = \frac{\partial f(X)}{\partial x_1} - \frac{\partial f(X)}{\partial x_2} \left(\frac{\partial g(X)}{\partial x_2} \right)^{-1} \frac{\partial g(X)}{\partial x_1}.$$

- ▶ Lokalinio minimumo taško galima ieškoti sprendžiant lygtį

$$\frac{df(X)}{dx_1} = 0.$$

Redukcijos metodas: pavyzdys

- ▶ Pavyzdžiui, uždavinio su tikslo funkcija $f(X) = x_1 + x_2$ ir apribojimu $g(X) = x_1^2 + x_2^2 - 1 = 0$ redukuota išvestinė lygi

$$\frac{df(X)}{dx_1} = 1 - \frac{x_1}{x_2}.$$

- ▶ Prilyginę pastarąją išvestinę nuliui ir įvertindami apribojimą gausime minimizavimo uždavinio sprendinį
 $x_1 = x_2 = -1/\sqrt{2}.$

Redukcijos metodas: iteracinis algoritmas

- ▶ Analitiškai išspręsti išvestinės lygybės nuliui lygtį galima tik specialiais atvejais.
- ▶ Tačiau redukuota išvestinė gali būti panaudota ir iteraciniam algoritmui sudaryti.
- ▶ Sakysim, žinomas leistinas sprendinys X .
- ▶ Įvertinę redukuotos išvestinės ženklą ir parinkę žingsnį pagal kintamąjį Δx_1 , nustatysime žingsnį pagal kintamąjį Δx_2 .
- ▶ Šiuo atveju svarbus tik redukuotos išvestinės ženklas.
- ▶ Naujas taškas gaunamas, kaip įprasta, iš taško X žengus žingsnį $(\Delta x_1, \Delta x_2)$.
- ▶ Gautasis taškas dažniausiai nepatenkina apribojimų ir todėl turi būti koreguojamas.
- ▶ Korekcija paprastai vykdoma sprendžiant lygtį $g(X) = 0$.
- ▶ Todėl šio metodo žingsnis negali būti ilgas.

Redukcijos metodas: daugelio kintamųjų atvejis

- ▶ Daugelio kintamųjų atveju metodas sudaromas analogiškai.
- ▶ Randamas tikslo funkcijos gradientas nepriklausomų kintamųjų atžvilgiu, įvertinant $m < n$ lygybinių apribojimų.
- ▶ Jis vadinamas redukuotu gradientu:

$$\nabla_R f(X) = \nabla_{X_1} f(X) - \nabla_{X_2} f(X) \cdot \left(\frac{\partial g(X)}{\partial X_2} \right)^{-1} \cdot \frac{\partial g(X)}{\partial X_1},$$

čia $X_1 = (x_1, \dots, x_{n-m})$ – nepriklausomų kintamųjų vektorius, $X_2 = (x_{n-m+1}, \dots, x_n)$ – priklausomų kintamųjų vektorius, o gradientų vektoriai suprantami kaip vektoriai-eilutės.

Redukcijos metodas: daugelio kintamųjų atvejis

- Dalinių išvestinių vektoriai šių kintamųjų atžvilgiu žymimi gradiento simboliu su atitinkamu indeksu, o vektorinės apribojimų funkcijos $g = (g_1, \dots, g_m)$ išvestinių matricos žymimos $\frac{\partial g(X)}{\partial X_1}$ ir $\frac{\partial g(X)}{\partial X_2}$

$$\frac{\partial g(X)}{\partial X_1} = \begin{pmatrix} \frac{\partial g_1}{\partial x_1} & \dots & \frac{\partial g_1}{\partial x_{n-m}} \\ \vdots & \ddots & \vdots \\ \frac{\partial g_m}{\partial x_1} & \dots & \frac{\partial g_m}{\partial x_{n-m}} \end{pmatrix},$$

$$\frac{\partial g(X)}{\partial X_2} = \begin{pmatrix} \frac{\partial g_1}{\partial x_{n-m+1}} & \dots & \frac{\partial g_1}{\partial x_n} \\ \vdots & \ddots & \vdots \\ \frac{\partial g_m}{\partial x_{n-m+1}} & \dots & \frac{\partial g_m}{\partial x_n} \end{pmatrix}.$$

Redukcijos metodas: daugelio kintamųjų atvejis

- Žingsnio kryptis $(\Delta X_1, \Delta X_2)$ parenkama šitaip:

$$\Delta X_1 = -\nabla_R f(X),$$

$$\Delta X_2 = -\nabla_R f(X) \cdot \left(\left(\frac{\partial g(X)}{\partial X_2} \right)^{-1} \cdot \frac{\partial g(X)}{\partial X_1} \right)^t.$$

- Kai apribojimai tiesiniai, kryptis neišveda iš leistinosios srities.
- Jei apribojimai netiesiniai, tai jie dažniausiai pažeidžiami.
- Todėl, žengus žingsnį, reikia koreguoti gautąjį tašką $X + \gamma(\Delta X_1, \Delta X_2)$.
- Paprastai Niutono metodu sprendžiama lygčių sistema $g(X) = 0$ kintamųjų X_2 atžvilgiu, esant fiksuotam $X_1 + \gamma \Delta X_1$.
- Taigi, kaip ir vartojant projekcijų metodą, gaunamas trumpas žingsnis, nors skaičiavimai ir komplikuoti.

Apribojimų klasės gradientų projekcijų ir redukcijų metoduose

- ▶ Tiek gradientų projekcijų, tiek gradientų redukcijų metodai (ypač pastaruoju metu pasiūlyti apibendrinti metodai) efektyvūs uždaviniams su tiesiniais apribojimais ir dideliu kintamųjų skaičiumi.
- ▶ Vienas iš pagrindinių apibendrinimų yra kintamos metrikos idėjų panaudojimas krypties parinkimui.
- ▶ Literatūroje paskelbta rezultatų, rodančių redukuotų gradientų tipo metodų efektyvumą sprendžiant kai kuriuos netiesinius uždavinius.
- ▶ Tiksliai apibrėžti jų klasę gana sunku, bet vaizdžiai tariant, galima ją nusakyti kaip klasę uždavinių su artimais tiesiniams apribojimams.

Lagrange'o funkcijų metodai

- ▶ Nagrinėdami būtinas minimumo sąlygas, pabrėžėme Lagrange'o funkcijos reikšmę netiesinio programavimo uždaviniams analizuoti.
- ▶ Jos pagrindu galima konstruoti ir minimizavimo metodus.
- ▶ Kaip jau buvo minėta, Lagrange'o funkcijos balno taškas nusako iškilo programavimo uždavinio sprendinį.
- ▶ Todėl metodas balno taškui ieškoti kartu yra ir metodas iškilojo programavimo uždaviniui spręsti.
- ▶ Priminsime, kad Lagrange'o funkcija vadinama

$$L(X, \Lambda) = f(X) + \sum_{i=1}^m \lambda_i g_i(X), \lambda_i \geq 0.$$

- ▶ Reikia rasti tašką (X_*, Λ_*) , tenkinantį nelygybes

$$L(X_*, \Lambda) \leq L(X_*, \Lambda_*) \leq L(X, \Lambda_*), \lambda_{*i} \geq 0.$$

Lagrange'o funkcijų metodai

- ▶ Kadangi pastarasis uždavinys yra su paprastais (neneigiamumo) apribojimais, tai jį galima spręsti gradientiniu metodu

$$X_{j+1} = X_j - \gamma_j \sum_{i=1}^m \mu_{ji} \nabla g_i(X_j),$$

$$\mu_{j+1} = (\mu_j + \gamma_j g(X_j))_+$$

čia ženklas $(\cdot)_+$ reiškia vektoriaus projekciją į teigiamą kvadrantą: t.y. aibę $\{\mu : \mu_i \geq 0, i = 1, \dots, m\}$, γ_j – žingsnio ilgio daugiklis.

- ▶ Tačiau kaip ir paprasti gradientiniai minimizavimo metodai, toks metodas nelabai efektyvus, o kartais juo apskritai nerandamas tikslus sprendinys.
- ▶ Antra vertus, lokalojo minimumo taškas išreiškiamas Lagrange'o funkcijos balno tašku tik esant gan griežtoms prielaidoms (iškilumas, regularumas).

Lagrange'o funkcijų metodai

- ▶ Bendru atveju tegalima teigti, kad Lagrange'o funkcija yra stacionari minimumo taške: jei X_* – lokiojo minimumo taškas, ir aktyviųjų apribojimų gradientai $\nabla g_i(X_*)$, $i \in I_*$, tiesiškai nepriklausomi, tai egzistuoja toks Λ_* , kad

$$\nabla f(X_*) + \sum_{i=1}^m \lambda_{*i} \nabla g_i(X_*) = 0,$$

ir X_* yra funkcijos $L(X, \Lambda_*)$ stacionarus taškas.

- ▶ Šiuo metodu pradinio uždavinio minimumo taškas nebūtinai bus rastas. Taip gali atsitikti, jei Lagrange'o funkcijos stacionarus taškas bus ne minimumo, o perlankio arba maksimumo taškas.
- ▶ Iš čia išplaukia natūralus noras “pataisyti” Lagrange'o funkciją taip, kad stacionarus taškas virstų minimumo tašku.

Lagrange'o funkcijų metodai

- ▶ Tą galima padaryti pridėjus prie $L(X, \Lambda)$ narį, kuris pats ir jo gradientas būtų lygus nuliui stacionariame taške, o tolstant nuo jo, pakankamai greitai didėtų. Viena iš paprasčiausių ir plačiausiai paplitusių modifikuotų Lagrange'o funkcijų yra

$$L_I(X, \Lambda, r) = f(X) + \sum_{i=1}^m \lambda_i g_i(X) + \frac{1}{r} \sum_{i \in I} g_i^2(X),$$

čia I – pažeistų apribojimų indeksų aibė.

- ▶ Galima įrodyti, kad egzistuoja baigtinis r_1 , užtikrinantis $L_I(X, \Lambda, r)$ hesiano teigiamą apibrėžtumą su visais $r < r_1$.
- ▶ Taigi X_* yra modifikuotos Lagrange'o funkcijos minimumo taškas.
- ▶ Ši išvada teisinga tik esant tam tikroms Λ ir r reikšmėms, kurios iš anksto nežinomos.
- ▶ Todėl modifikuotų Lagrange'o funkcijų pagrindu kuriamuose methoduose turi būti apskaičiuoti priimtini šių reikšmių įverčiai.

Lagrange'o funkcijų metodai

- ▶ Baudos daugiklio r įtaką nesunku suprasti, prisiminus baudos metodų aptarimą.
- ▶ Parinkę per mažą r reikšmę, turėsime staigiai kylantį funkcijos reljefo šlaitą tuoj už leistinosios srities ribos.
- ▶ Anksčiau buvo pabrėžta, kad tokią funkciją minimizuoti sunku, ypač kai srities riba kreiva.
- ▶ Kai r reikšmė per didelė, gali nepavykti transformuoti Lagrange'o funkcijos stacionaraus taško į minimumo tašką.
- ▶ Jei būtų žinoma daugiklių vektoriaus reikšmė Λ_* , tai netiesinio programavimo uždavinį galėtume išspręsti, vieną kartą minimizuodami modifikuotą Lagrange'o funkciją (be apribojimų).
- ▶ Tačiau sprendžiant realius uždavinius Λ_* būna nežinomas, ir jį tenka vertinti naudojantis informacija apie $f(X)$ ir $g_i(X)$, $i = 1, \dots, m$, gauta ankstesnėse iteracijose.

Lagrange'o funkcijų metodai

- Panagrinėsime specialų minimizavimo uždavinio atvejį, kai nėra nelygybinių apribojimų

$$\min_{G(X)=0} f(X), \quad G(X) = (g_1(X), \dots, g_m(X))^t.$$

- Šiuo atveju modifikuota Lagrange'o funkcija lygi

$$L(X, \Lambda, r) = f(X) + \sum_{i=1}^m \lambda_i g_i(X) + \frac{1}{2r} \sum_{i=1}^m g_i^2(X),$$

o jos gradientas išreiškiamas formule

$$\nabla_X L(X, \Lambda, r) = \nabla f(X) + \sum_{i=1}^m (\lambda_i + \frac{1}{r} g_i(X)) \nabla g_i(X).$$

Lagrange'o funkcijų metodai

- ▶ Algoritmui pradėti reikia pasirinkti pradines Λ ir r reikšmes.
- ▶ Turint einamąsias Lagrange'o ir baudos daugiklių reikšmes, Λ_k , r_k , sprendžiamas minimizavimo be apribojimų uždavinys

$$\min L(X, \Lambda_k, r_k).$$

- ▶ Išsprendus šį uždavinį, gaunamas naujas minimumo taško įvertis X_k .
- ▶ Remiantis modifikuotos Lagrange'o funkcijos gradiento lygybe nuliui taške X_k Lagrange'o daugikliai perskaičiuojami pagal formulę

$$\Lambda_{k+1} = \Lambda_k + \frac{1}{r_k} G(X_k).$$

- ▶ Baudos daugiklis sumažinamas padauginant jį iš koeficiento: $r_{k+1} = \tau r_k$, $0 < \tau < 1$.
- ▶ Galima įrodyti, kad esant pakankamai bendroms prielaidoms, toks metodas konverguoja į lokalųjį minimumą.

Lagrange'o funkcijų metodai

- ▶ Jei uždavinyje be lygybinių yra ir nelygybiniai apribojimai, pastaruosius galima pakeisti lygybiniais uždavinio kintamuosius papildant fiktyviaisiais kintamaisiais.
- ▶ Kitokia metodo versija, kurioje einamasis taškas nustatomas minimizavimu.
- ▶ Šiuo atveju reikšmę turi aktyviųjų apribojimų aibės nustatymo būdas.
- ▶ Aktyvieji apribojimai dažniausiai prognozuojami kiekvienam minimizavimo (be apribojimų) kintamųjų vektoriaus X atžvilgiu ciklui.
- ▶ Įvairūs modifikuotų Lagrange'o funkcijų metodai skiriasi baudos ir Lagrange'o daugiklių perskaičiavimo, aktyviųjų apribojimų aibės nustatymo, minimizavimo kintamųjų vektoriaus X atžvilgiu būdais.
- ▶ Praktinis metodo efektyvumas priklauso ir nuo programinės realizacijos.

Lagrange'o funkcijų metodai

- ▶ Lagrange'o funkcijomis pagrįstų metodų efektyvumo laidas – apribojimų įvertinimas Lagrange'o daugikliais, kai baudos narys tik “pataiso” Lagrange'o funkciją; todėl baudos daugiklį daug lengviau įvertinti negu tiesiogiai taikomos baudos metoduose.
- ▶ Lagrange'o daugiklių įverčiai perskaičiuojami iteraciniais metodais, kurių iteracijos eina pakaitomis su funkcijos minimizavimo X atžvilgiu iteracijomis (kintamos metrikos metodu).
- ▶ Efektyvūs netiesinio programavimo metodai sukurti remiantis panašia idėja.
- ▶ Nors bendru atveju Lagrange'o funkcijos stacionarus taškas X atžvilgiu nebūtinai yra minimumo tašku, bet tam tikru būdu parinkę X kitimo aibę, galime garantuoti, kad šioje aibėje stacionarus taškas būtų minimumo tašku.

Lagrange'o funkcijų metodai

- ▶ Sakykime, X_* – lokalo minimumo taškas, o λ_{*i} , $i \in I$ tokie, kad

$$\nabla f(X_*) + \sum_{i \in I} \lambda_{*i} \nabla g_i(X_*) = 0,$$

čia I – aktyvių taške X_* apribojimų indeksų aibė.

- ▶ Tada X_* yra funkcijos $L(X, \Lambda_*)$ minimumo taškas aibėje, kurią apibrėžia ortogonalūs aktyvių apribojimų gradientams vektoriai.
- ▶ Taigi, žinodami Λ_* , galėtume rasti X_* vieną kartą minimizuodami Lagrange'o funkciją aibėje, aprašytoje tiesiniais apribojimais.
- ▶ Kadangi Λ_* nežinomas, tai jį reikia įvertinti naudojantis informacija apie tikslo ir apribojimų funkcijas, gaunama minimizavimo eigoje.
- ▶ Metodą sudaro viena kitą keičiančios iteracijos: Lagrange'o daugiklių įverčių tikslinimo ir Lagrange'o funkcijos minimizavimo X atžvilgiu.

Lagrange'o funkcijų metodai

- ▶ Tiksliai minimizuoti Lagrange'o funkciją esant netiksliams Λ_* įverčiams dažniausiai neverta.
- ▶ Todėl vietoj šio minimizavimo uždavinio formuluojamas kvadratinio programavimo uždavinys, kurio tikslo funkcija yra kvadratine funkcija aproksimuota Lagrange'o funkcija.
- ▶ Ji konstruojama naudojantis Hesiano perskaičiavimo formulėmis, kaip ir kintamos metrikos metoduose.
- ▶ Kvadratinio programavimo uždaviniams spręsti yra labai efektyvių algoritmų, todėl ši iteracija nekelia problemų.
- ▶ Modifikuotomis Lagrange'o funkcijomis pagrįstų metodų efektyvumą lemia Lagrange'o daugiklių įverčių ir Hesiano perskaičiavimo metodai.
- ▶ Modifikuotų Lagrange'o funkcijų metodai yra vieni iš efektyviausių netiesinio programavimo uždaviniams su diferencijuojamomis tikslo ir apribojimų funkcijomis spręsti, kai kintamųjų skaičius nelabai didelis (iki kelių šimtų).
- ▶ Šie metodai ypač efektyvūs uždaviniams su tiesiniais apribojimais.

Netiesinio programavimo metodų aptarimas

- ▶ Paprasčiausi yra uždaviniai su diferencijuojamomis tikslo funkcijomis ir tiesiniais apribojimais.
- ▶ Jiems spręsti sukurta daug efektyvių metodų ir juos realizuojančios programinės įrangos.
- ▶ Uždaviniai su tiesiniais apribojimais netgi paprastesni už uždavinius be apribojimų ta prasme, kad dėl ribojimų sumažėja leistinosios aibės dimensija.
- ▶ Uždaviniams su tiesiniais apribojimais efektyvūs projekcijų ir redukcijų metodai, nes šie metodai realizuojami nesudėtingomis matricų daugybos operacijomis.
- ▶ Lagrange'o funkcijų metodai taip pat tinka minimizavimo uždaviniams su tiesiniais apribojimais.
- ▶ Tais atvejais, kai tikslo funkcija daugiaekstremė arba jai būdingi kitokie nereguliarumai, retai pavyksta pasinaudoti tiesinių apribojimų specifika.

Netiesinio programavimo metodų aptarimas

- ▶ Lokaliojo minimizavimo su netiesiniais apribojimais uždaviniams, kai tikslo ir apribojimų funkcijos diferencijuojamos, o kintamųjų nelabai daug (iki kelių šimtų), efektyviausi yra Lagrange'o funkcijų metodai.
- ▶ Jie visapusiškai ištyrinėti, juos realizuojančios kompiuterių programos eksploatuojamos ilgus metus.
- ▶ Todėl programų konstrukcija yra išbaigta, sukurti gana tobuli pagalbinių uždavinių sprendimo metodai.
- ▶ Tačiau šie metodai nelabai tinka tais atvejais, kai tikslo ar apribojimų funkcijos nediferencijuojamos.
- ▶ Jei skaičiavimo paklaidos pernelyg didelės, tai skaitmeniškai vertinant dalines išvestines, galima gauti beprasmius rezultatus.

Netiesinio programavimo metodų aptarimas

- ▶ Svarbi efektyvaus netiesinio programavimo metodų panaudojimo sąlyga yra tinkamas tikslo ir apribojimų funkcijų bei nepriklausomų kintamųjų mastelio parinkimas.
- ▶ Teoriškai metodai dažniausiai invariantiniai mastelių atžvilgiu, tačiau garantuoti, kad šią savybę turės ir jų realizacijos, negalima.
- ▶ Viena iš priežasčių ta, kad kompiuterio programos vykdo veiksmus ne tik su santykiniais bet ir su absoliučiais dydžiais.
- ▶ Pavyzdžiui, kompiuteriu minimizuojant ta pačia gradientinio tipo metodą realizuojančia kompiuterio programa funkcijas $f(X)$ ir $10^{-20}f(X)$, vargu ar galima tikėtis to paties atsakymo (suprantama, atsižvelgiant į funkcijos reikšmės mastelį) jau vien dėl to, kad antrajai funkcijai daugelis taškų bus laikoma optimaliais dėl mažesnės už kompiuterio programoje užfiksuotas ribines gradiento normos reikšmes.

Netiesinio programavimo metodų aptarimas

- ▶ Beveik visiems algoritmams nepageidautina, kad funkcijos variacija būtų artima nuliui.
- ▶ Taip pat nepageidautinos didelio absoliutaus didumo funkcijos reikšmės.
- ▶ Kuriant taikomojo uždavinio matematinį modelį, rekomenduotina funkcijos reikšmėms parinkti tokį mastelį, kad jos minimumas būtų apie vieneta, o maksimalios reikšmės, pakeltos kubu, būtų ne didesnės už maksimalų kompiuterio skaičių.
- ▶ Sudėtingiau parinkti nepriklausomų kintamųjų ir apribojimų funkcijų mastelius.
- ▶ Gerai apibrėžta laikoma tokia funkcija, kurios nepriklausomų kintamųjų vienodi pokyčiai sukelia tos pačios eilės funkcijos prieaugius.

Netiesinio programavimo metodų aptarimas

- ▶ Specialioje literatūroje galima rasti samprotavimų, kaip tiesiškai transformuoti nepriklausomus kintamuosius, kad būtų optimaliai suderinti masteliai.
- ▶ Kadangi praktiškai juos realizuoti ne taip paprasta, dažniausiai apsiribojama tik natūralių uždavinio nepriklausomų kintamųjų mastelio parinkimu.
- ▶ Apribojimų funkcijoms šalia gero apibrėžtumo keliamas papildomas reikalavimas – jų įtaka turi būti apylygė, t.y. vienodo dydžio nepriklausomų kintamųjų pokyčiai turėtų iššaukti tos pačios eilės apribojimų funkcijų pokyčius.
- ▶ Geriausi netiesinio programavimo algoritmai automatiškai parenka priimtinius mastelius, tačiau vartotojas, formuluodamas uždavinį, turėtų atsižvelgti į šias paprastas rekomendacijas.
- ▶ Mastelių parinkimo neįmanoma visiškai automatizuoti, o formuluojant uždavinį įvertinti šiuos samprotavimus dažniausiai ne taip jau sunku.

Netiesinio programavimo metodų aptarimas

- ▶ Uždaviniams su apribojimais, kaip ir be jų, viena iš pagrindinių rekomendacijų – panaudoti kuo išsamesnę informaciją apie funkcijų išvestines.
- ▶ Kai tikslo ir netiesinės apribojimų funkcijos diferencijuojamos, efektyviausi yra Lagrange'o funkcijų metodai.
- ▶ Tą patvirtina gausūs eksperimentinių tyrimų rezultatai paskelbti literatūroje.
- ▶ Tačiau šie metodai netinka uždaviniams, kurių tikslo funkcija neapibrėžta už leistinosios srities ribų.
- ▶ Tokiu atveju vartotinas barjerų metodas.

Netiesinio programavimo metodų aptarimas

- ▶ Daug sudėtingiau parinkti efektyvų metodą, kai funkcijų reikšmės tegalima apskaičiuoti duotuoju algoritmu, kurio paklaidos tokios didelės, kad skaitmeniškai diferencijuoti beprasmiška.
- ▶ Tada apribojimai įvertinami baudos arba barjerų metodais, o uždavinys be apribojimų sprendžiamas pagal vieną iš tiesioginio ieškojimo algoritmų.
- ▶ Kuriant tokius metodus, daug ką tenka spręsti euristiškai. Todėl sunku apibrėžti jų racionalaus panaudojimo sritį.

Netiesinio programavimo metodų aptarimas

- ▶ Daugiaekstremiai uždaviniai su bendro pobūdžio netiesiniais apribojimais baudos metodu dažniausiai pakeičiami uždaviniais su paprastais apribojimais, kuriems skirta dauguma globaliojo minimizavimo metodų.
- ▶ Šis būdas grindžiamas tuo, kad kuriant globaliuosius metodus, apie tikslo funkciją paprastai daromos tik labai bendros prielaidos.
- ▶ Taigi natūralu perkelti į tikslo funkciją visus uždavinio sunkumus, nes pagrindinės prielaidos lieka patenkintos.
- ▶ Kadangi baudos daugiklis parenkamas gana laisvai, o globaliojo minimizavimo metodais minimumas nustatomas labai apytiksliai, tai tokiu metodu gautą sprendinį verta patikslinti lokaliajo netiesinio programavimo metodu, kuris parenkamas atsižvelgiant į tikslo funkcijos ir apribojimų savybes.

Netiesinio programavimo metodų aptarimas

- ▶ Kai kuriuose, dažniausiai atsitiktinio globaliojo ieškojimo, metoduose apribojimai vertinami taip: minimizuojama hiperstačiakampyje, aprašytame apie leistinąją sritį.
- ▶ Jei taškas patenka į leistinąją sritį, imama tikslo funkcijos reikšmė, jei ne – koks nors didelis skaičius.
- ▶ Tačiau šis metodas visiškai netinka dažnai pasitaikantiems uždaviniams, kurių leistinosios srities hipertūris yra labai mažas palyginti su aprašyto hiperstačiakampio, t.y. tikimybė pataikyti į leistinąją sritį artima nuliui.
- ▶ Beje šį metodą galima interpretuoti kaip baudos metodą su trūkia baudos funkcija.

Netiesinio programavimo metodų aptarimas

- ▶ Kartais kyla nesusipratimų dėl gauto optimizavimo uždavinio sprendinio tikslumo.
- ▶ Dažnas nepatyręs vartotojas, nurodęs baigimo sąlygų parametą ε , tikisi, kad rastas sprendinys skiriasi nuo tikrojo ne daugiau ε .
- ▶ Tokia nuomonė susiformuoja naudojantis paprastesnių uždavinių sprendimo algoritmais, kurie garantuoja randamo sprendinio tikslumą.
- ▶ Pavyzdžiui, pagal standartines sinuso arba kvadratinės šaknies radimo paprogrames funkcijos reikšmė apskaičiuojama mašininio tikslumu.
- ▶ Netiesinio programavimo metodai gali garantuoti randamo sprendinio tikslumą tik labai specialiais atvejais.
- ▶ Praktiškai baigimo sąlygos apibrėžiamos keliais būdais.

Netiesinio programavimo metodų aptarimas

- ▶ Gradientinio tipo metodų viena iš baigimo sąlygų yra būtinų minimumo sąlygos patenkinimas metodo vartotojo užduotu tikslumu.
- ▶ Tačiau tokias sąlygas (ypač neiškiliųjų funkcijų atveju) gali tenkinti taškai, esantys toli nuo lokalojo minimumo taško.
- ▶ Todėl sustojimo sąlyga gali būti tenkinama ne tik lokalojo minimumo aplinkoje, bet ir nutolusiuose nuo jo “spąstuose”.
- ▶ Kitos, ypač tiesioginio ieškojimo metodų, sustojimo sąlygos išreiškia minimizavimo proceso sulėtėjimą, t.y. menką rastojo taško bei funkcijos reikšmės kitimą keliose iš eilės einančiose iteracijose.
- ▶ Tai būdinga lokalojo minimumo aplinkai, bet vėlgi ne tik jai.
- ▶ Galima pabandyti iš gauto arba kito taško minimizuoti tuo pačiu metodu su kitais parametrais arba kitu metodu.
- ▶ Dažnai sprendinio analizei būna naudinga tikslo ir apribojimų funkcijų pjūvius per gautąjį tašką pavaizduoti grafiškai.

Netiesinio programavimo metodų aptarimas

- ▶ Galima pabrėžti, kad netiesinio programavimo uždaviniai sudėtingi ir nėra universalių metodų jiems spręsti.
- ▶ Parenkant metodą, reikia atidžiai palyginti uždavinio savybes ir prielaidas, kuriomis pagrįstas tas ar kitas metodas.
- ▶ Nors matematinė optimizavimo teorija gerai išvystyta, bet sėkmingam sudėtingų praktikos uždavinių sprendimui reikia tam tikros patirties.

Istorinės pastabos

- ▶ Paprasčiausios būtinios minimumo sąlygos diferencijuojamai vieno kintamojo funkcijai išreiškiamos išvestinės lygybe nuliui. Šios sąlygos dažnai vadinamos Fermat (1601-1665) teorema, nors tuo metu, kai kūrė P.Fermat, išvestinės sąvoka dar nebuvo griežtai suformuluota.
- ▶ Būtinias lokolio minimumo sąlygas uždaviniams su lygybiniais apribojimais suformulavo žymus matematikas ir mechanikas J.Lagrange, gyvenęs 1763-1813. Vėliau Lagrange'o metodas buvo panaudotas įvairiems uždaviniams spręsti, bet nagrinėjamais atvejais apribojimai būdavo lygybės tipo.
- ▶ Pirmuosius rezultatus apie būtinias minimumo sąlygas uždaviniams su nelygybės tipo apribojimais gavo W.Karush savo magistriniame darbe apgintame Čikagos universitete 1939 metais.

Istorinės pastabos

- ▶ Kitas, taip pat likęs nepaskelbtu darbas apie būtiną minimumo sąlygas uždaviniams su nelygybiniais apribojimais buvo parašytas F.John'o, kuris nagrinėjo uždavinius apie elipsoidų tūrius. F.John pateikė straipsnį 1939 metais solidžiam matematikos žurnalui Duke Mathematical Journal, kurio redakcija straipsnį atmetė. Darbas buvo paskelbtas 1948 metais knygoje, skirtoje žymaus amerikiečių matematiko R.Courant, kuris domėjosi optimizavimu, šešiasdešimtmečiui.
- ▶ Po to, kai 1951 metais H.Kuhn ir A.Tucker paskelbė garsųjį straipsnį apie būtiną minimumo sąlygas, ši tematika buvo pripažinta solidžia ir aktualia matematikos kryptimi. Beje, šiame straipsnyje buvo pirmą kartą pavartotas terminas netiesinis programavimas. Šiuo metu moksliniai straipsniai ir knygos, kuriuose remiamasi minimumo sąlygomis, skaičiuojami šimtais. Retas rezultatas cituojamas taip dažnai, kaip Kuhn-Tucker sąlygos.